

Atracciones que Enamoran: Cómo un modelo aprende qué gusta a los visitantes

Diógenes Lugo
Data Scientist · BI Consultant
Madrid, España
KeepCoding 01-02-2026

Abstract

Cada año, las plataformas digitales de turismo incorporan miles de nuevas atracciones, experiencias y puntos de interés. Sin embargo, no todas recibirán inversión en promoción, serán destacadas por los usuarios o justificarán acuerdos comerciales. Como consecuencia, muchas decisiones sobre inversión y visibilidad se toman tarde, cuando el engagement ya es evidente, o basadas en intuición, generando pérdida de oportunidades y recursos.

Este trabajo plantea una pregunta estratégica: ¿es posible anticipar qué atracciones tienen alto potencial de engagement antes de que el mercado lo confirme? Para abordarla, se desarrolla un modelo de Deep Learning multimodal que integra imágenes y metadatos de los puntos de interés, permitiendo identificar patrones que predicen la interacción futura de los usuarios.

El enfoque ofrece a las plataformas digitales una herramienta para tomar decisiones informadas, optimizar la inversión en promoción y obtener ventaja competitiva al detectar tempranamente los POIs con mayor potencial, transformando datos dispersos en insights accionables.

1 Introducción

En un mercado de turismo digital saturado, cada año se suman miles de nuevas atracciones y experiencias. Para las plataformas, el desafío no es solo almacenar esta información, sino priorizarla estratégicamente: decidir qué experiencias promocionar, qué acuerdos comerciales cerrar y dónde invertir recursos limitados. Tradicionalmente, estas decisiones se basan en intuición o en métricas observadas demasiado tarde, cuando el engagement ya se ha manifestado, generando oportunidades perdidas y asignación ineficiente de inversión.

La propuesta de este proyecto parte de una pregunta estratégica: *¿es posible anticipar qué atracciones tienen alto potencial de engagement antes de que el mercado lo confirme?*. Este planteamiento introduce tres conceptos clave: anticipación —para generar valor antes de la competencia—, potencial —ya que no toda predicción es certeza— y ventaja temporal —permitiendo actuar antes de que los resultados se consoliden en métricas históricas.

Para transformar esta problemática de negocio en un problema de datos, se define el engagement observado como proxy del valor percibido por los usuarios. Se combinan métricas históricas (visitas, likes, bookmarks) con señales tempranas extraídas de imágenes y metadatos, permitiendo construir un modelo escalable que priorice las atracciones con mayor potencial, detecte outliers y optimice decisiones estratégicas. Así, la analítica no reemplaza la toma de decisiones, sino que la guía, permitiendo a las plataformas actuar de manera informada y proactiva.

2 Antecedentes y Motivación

En el contexto del turismo digital, las decisiones humanas sobre qué atracciones visitar combinan información visual y contextual. Una imagen por sí sola puede transmitir el atractivo estético, el estado de conservación o el tipo de experiencia que ofrece un lugar, mientras que los metadatos aportan información crítica sobre accesibilidad, ubicación geográfica o categoría funcional. Separadas, estas señales son incompletas; juntas, reflejan de manera

más fiel cómo un usuario evalúa una atracción y percibe su valor.

Esta observación justifica un enfoque multimodal para la predicción del engagement: integrar imágenes y metadatos permite capturar la riqueza de información que guía las decisiones de los usuarios y que, a su vez, es clave para priorizar estratégicamente las inversiones en promoción y acuerdos comerciales. Así, el modelo no se limita a aprender patrones de manera aislada, sino que refleja cómo un humano combina distintas fuentes de información para evaluar el potencial de una atracción.

Históricamente, las plataformas de turismo han manejado sus datos de forma fragmentada, con métricas aisladas y reportes ad-hoc que no permitían anticipar tendencias ni priorizar oportunidades de manera proactiva. La integración de señales visuales y contextuales ofrece una base más completa y confiable para decisiones informadas, escalables y replicables, alineando la arquitectura de datos con los objetivos de negocio y la estrategia de engagement.

3 Metodología

3.1 Análisis Exploratorio de Datos (EDA)

La primera etapa del proyecto consiste en comprender en profundidad el tamaño y la estructura del conjunto de datos. Se analiza el número total de observaciones y variables, así como el tipo de dato asociado a cada columna, con el objetivo de verificar la coherencia entre su significado semántico y su representación. Esta revisión inicial permite identificar variables que requieran conversión de tipo y anticipar decisiones de preprocesado, como normalización, codificación o imputación de valores.

A continuación, se evalúa la calidad de los datos disponibles. Este análisis incluye la detección de valores nulos o ausentes, registros duplicados y valores incoherentes o atípicos, como métricas negativas o combinaciones imposibles de variables. La finalidad es determinar el grado de confiabilidad de la información y la necesidad de aplicar técnicas de limpieza o corrección antes de

la construcción del modelo.

Paralelamente, se analizan los rangos, estadísticas descriptivas y distribuciones de las variables numéricas, así como las frecuencias de las variables categóricas. Este análisis permite detectar posibles *outliers*, distribuciones sesgadas o escalas heterogéneas que puedan requerir transformaciones específicas. Comprender estas características resulta clave para seleccionar estrategias de preprocesamiento adecuadas y prevenir problemas durante el entrenamiento del modelo.

De forma complementaria, se realiza una inspección visual preliminar del material gráfico asociado a los POIs con el objetivo de contextualizar el tipo de contenido que será procesado por la red. Tal como se observa en la Figura 1, estas representaciones presentan una elevada heterogeneidad en términos de encuadre, iluminación y composición, lo que refuerza la necesidad de un preprocesamiento robusto y de un enfoque capaz de extraer patrones visuales relevantes más allá de variaciones superficiales.




Figure 1: Ejemplos representativos del material visual asociado a distintos puntos de interés turístico.

Adicionalmente, se analiza la distribución geográfica de los puntos de interés a partir de sus coordenadas de latitud y longitud. Este análisis permite verificar la coherencia espacial del dataset, identificar posibles errores de geolocalización y comprender la concentración territorial de los POIs. Tal como se muestra en la Figura 2, la mayoría de las atracciones se agrupan en zonas urbanas y áreas de alta actividad turística, un patrón consistente con el comportamiento esperado del dominio. Esta información resulta relevante para interpretar posteriormente el engagement observado, ya que factores como la accesibilidad, la densidad turística y el contexto urbano influyen directamente en la visibilidad y la interacción de los usuarios.



Figure 2: Distribución geográfica de los puntos de interés turísticos a partir de sus coordenadas de latitud y longitud.

A partir de los análisis anteriores, se identifican los desafíos que deberán abordarse en la fase de preprocesado. Entre ellos se incluyen columnas irrelevantes o redundantes, variables categóricas de alta cardinalidad y métricas de engagement con distribuciones desbalanceadas. Este diagnóstico temprano facilita la construcción de un pipeline de preprocesado robusto y alineado con los objetivos de negocio.

Finalmente, se realiza una inspección preliminar de la variable objetivo, **el engagement**, evaluando su distribución y posibles desbalances entre clases. Este análisis permite confirmar la viabilidad del problema de predicción,

anticipar la necesidad de técnicas de ajuste como ponderación de clases o muestreo, y asegurar que el target refleja de manera coherente el valor percibido por los usuarios. Con ello, la EDA inicial establece las bases para las etapas posteriores de preprocesado y modelado.

3.2 Definición del Target y Selección de Variables

El primer paso para establecer una estrategia de predicción efectiva es definir claramente la variable **objetivo**, que en nuestro caso busca resumir el interés de los usuarios por cada punto de interés (POI). Se analizaron las métricas disponibles, incluyendo **visitas, likes, bookmarks y dislikes** con el objetivo de determinar cuál combinación reflejaría de manera más fiel el engagement real de los usuarios.

Con el objetivo de definir una variable objetivo que represente de forma compacta el interés de los usuarios por cada punto de interés, se optó por construir una métrica de engagement basada en una combinación heurística de las señales disponibles. Dado que el valor real percibido por los usuarios no es directamente observable, las métricas históricas de interacción (likes, bookmarks y dislikes) se emplean como señales indirectas de dicho interés.

El uso de un enfoque heurístico responde a una decisión consciente de diseño: en esta fase no se busca aprender el engagement, sino definir una proxy razonable, estable e interpretable que sirva como base para el entrenamiento del modelo. Fijar explícitamente los pesos permite controlar el impacto relativo de cada señal, penalizar la interacción negativa y evitar que métricas con alta varianza dominen el score final. Adicionalmente, para mitigar diferencias de escala y distribuciones sesgadas, se aplican transformaciones logarítmicas que estabilizan la contribución de cada componente. La métrica de engagement resultante se define formalmente como:

$$\text{engagement_score} = \underbrace{\log(1 + \beta \cdot \text{Likes} + \gamma \cdot \text{Bookmarks})}_{\text{feedback positivo}} - \underbrace{\log(1 + \delta \cdot \text{Dislikes})}_{\text{feedback negativo}}$$

donde los pesos heurísticos se definieron como $\beta = 0.3$, $\gamma = 0.4$ y $\delta = 0.1$. Estos valores reflejan la importancia relativa de cada métrica: γ asigna mayor peso a los **bookmarks** por indicar compromiso real del usuario, β pondera los **likes** como señal positiva de interés, y δ penaliza levemente los **dislikes** para reflejar feedback negativo. Esta combinación permite capturar de manera equilibrada el feedback positivo y negativo de los usuarios, asegurando que la variable objetivo refleje fielmente el potencial de engagement antes de que se observe un comportamiento masivo en el mercado.

Finalmente, se definió la naturaleza del problema, la variable objetivo podría abordarse tanto como un problema de regresión, para predecir un valor continuo de *engagement*, como un problema de clasificación, categorizando los POIs en niveles de alto y bajo *engagement*. La elección final recayó en un clasificador, dado que esta aproximación facilita la interpretación y la toma de decisiones de negocio, permitiendo priorizar de manera directa las atracciones con mayor potencial antes de que los usuarios confirmen su interés mediante interacción. Además, la clasificación permite gestionar de forma más estable las métricas de engagement, reducir el impacto de outliers y simplificar la integración de la variable objetivo con los procesos de promoción, posicionamiento y acuerdos comerciales que se abordarán en fases posteriores del modelo.

3.3 Preprocesado de Datos

Durante la fase de preprocesado de datos se implementaron los pasos necesarios para garantizar la calidad y consistencia del conjunto de datos. Primero, se identificaron y eliminaron registros duplicados, así como inconsistencias detectadas durante la exploración, asegurando que cada punto de interés (POI) contara con información única y confiable.

A continuación, se transformaron las columnas de tipo objeto, como categorías y etiquetas, a formatos adecuados para el análisis, aplicando codificación y normalización según correspondía. En particular, la columna *categories*, que contiene listas de hasta 12 etiquetas por POI (por ejemplo, ['Historia', 'Cultura']), se procesó mediante un embedding de índices. Esta decisión permite convertir la información textual en vectores numéricos de

baja dimensión que el modelo puede interpretar directamente.

El uso de embeddings de índices ofrece varias ventajas: primero, reduce la dimensionalidad de la entrada; con 12 categorías, un embedding de 8 dimensiones representa cada POI mediante 8 números en lugar de 12 valores dispersos como en un *one-hot*, lo que simplifica el entrenamiento y mejora la eficiencia. Segundo, permite capturar relaciones semánticas entre categorías; por ejemplo, el modelo puede aprender que 'Historia' y 'Patrimonio' están relacionadas y colocarlas cerca en el espacio vectorial, algo que no sería posible con codificación binaria clásica. Esta representación más rica facilita que la red aprenda patrones más complejos y generalice mejor sobre nuevos POIs.

Finalmente, se prepararon y consolidaron todas las métricas de engagement definidas previamente, incluyendo la clasificación por categorías de engagement (`eng_cat`) y el puntaje compuesto (`engagement_score`). Durante esta etapa, se aseguró que los valores estuvieran normalizados, libres de inconsistencias y adecuadamente codificados, incluyendo la representación de las columnas categóricas mediante embeddings de índices cuando correspondía. De esta manera, los datos quedaron completamente estructurados y listos para su utilización en la fase de modelado, garantizando que la red neuronal pueda procesarlos de manera eficiente y aprovechar al máximo la información disponible para aprender patrones de engagement en los POIs.

3.4 Arquitectura de la Red Neuronal

La fase de modelado consistió en diseñar una arquitectura de red neuronal capaz de integrar de manera conjunta la información visual y los metadatos asociados a cada punto de interés. La red se estructuró en módulos especializados que cumplen funciones complementarias: un componente convolucional (CNN) encargado de procesar las imágenes de las atracciones, extrayendo características relevantes que capturan el atractivo estético, el estado de conservación y el tipo de experiencia ofrecida, y un componente de capas totalmente conectadas (*fully-connected*) dedicado a procesar los metadatos, tales como ubicación geográfica, categoría funcional y accesibilidad. La información extraída por la CNN se combina con los vectores de metadatos en capas posteriores, permitiendo que la red aprenda relaciones

entre las señales visuales y contextuales, y genere predicciones de engagement que reflejen de manera holística el potencial de cada atracción Figura 3. Esta arquitectura modular asegura que cada tipo de dato contribuya de manera adecuada al aprendizaje, facilitando interpretabilidad y estabilidad en la estimación del target.




Figure 3: Ilustración de la arquitectura de la red neuronal y su flujo interno de decisión integrando señales visuales y metadatos.

Ambos flujos de información convergen en una capa de fusión que integra las señales visuales extraídas por la CNN y los vectores de metadatos, generando una representación conjunta y enriquecida de cada punto de interés. Esta representación integrada alimenta las capas finales del modelo, compuestas por capas totalmente conectadas y funciones de activación adecuadas para clasificación. La red está diseñada específicamente para predecir el potencial de engagement de cada POI, categorizándolo en niveles de **alto** o **bajo engagement**, conforme a la definición de target establecida previamente. Este enfoque permite que el modelo no solo identifique patrones complejos en la información multimodal, sino que también facilite la toma de decisiones de negocio, priorizando atracciones con mayor probabilidad de éxito y propor-

cionando interpretabilidad sobre las predicciones generadas.

Para mejorar la capacidad de generalización y prevenir sobreajuste, se implementaron técnicas de regularización, incluyendo **Dropout** y normalización de capas. La selección de la función de pérdida y la optimización de los hiperparámetros se realizó de manera controlada, evaluando el desempeño del modelo en conjuntos de validación. Este enfoque permitió asegurar que la arquitectura final no solo capturara la complejidad inherente del problema, sino que también ofreciera escalabilidad, robustez y estabilidad en sus predicciones. Con la red entrenada y los datos procesados, se procede a la siguiente sección donde se presentan y analizan los **resultados obtenidos** y la capacidad de la red para clasificar los POIs según su potencial de engagement.

4 Resultados

En esta sección se presentan los resultados obtenidos tras el entrenamiento y evaluación del modelo propuesto. El objetivo principal es analizar su capacidad para identificar y clasificar puntos de interés según su nivel de engagement, evaluando tanto el desempeño global como el comportamiento del modelo frente a distintas categorías. Las métricas seleccionadas permiten interpretar no solo la precisión de las predicciones, sino también su utilidad práctica en un contexto de toma de decisiones, proporcionando una base sólida para discutir las fortalezas y limitaciones del enfoque planteado.

El modelo **EngageNet** alcanzó una **exactitud global del 85.27 %**, mostrando un desempeño sólido y estable a lo largo del proceso de entrenamiento y validación. Al analizar los resultados por clase, se observa que las categorías **Low** y **High** presentan niveles elevados de precisión y recobrado, lo que indica que el modelo identifica de forma fiable los puntos de interés con engagement bajo y alto. En contraste, la clase **Mid** muestra un rendimiento ligeramente inferior, lo cual es esperable debido a la mayor dificultad para distinguir casos con un nivel de engagement intermedio.

En conjunto, estos resultados confirman que la red es capaz de **aprovechar información visual y contextual relevante**, cumpliendo adecuadamente

con el objetivo del proyecto: **apoyar la priorización de atracciones con mayor potencial** y facilitar una toma de decisiones más informada desde el punto de vista de negocio.

Para evaluar la estabilidad del entrenamiento y la convergencia del modelo, se realizaron seguimientos de las curvas de pérdida y exactitud tanto en el conjunto de entrenamiento como en el de validación. Como se ilustra en la Figura 4, a partir de la época 13 las curvas se estabilizan, indicando un ajuste adecuado sin sobreajuste y una capacidad generalizable para nuevos POIs.




Figure 4: Evolución de la pérdida y la exactitud durante el entrenamiento del modelo EngageNet, mostrando convergencia y estabilidad a partir de la época 13.

En las siguientes tablas se reflejan las metricas con más detalle sobre la generalización y comportamiento del modelo con datos no vistos. (Tabla 1).

Table 1: Métricas globales del modelo EngageNet

Métrica global	Valor
Accuracy (test)	85 %
Macro-F1	0.85
Soporte total	224

El desglose por clase muestra un **rendimiento especialmente elevado en las clases extremas**, donde el modelo clasifica con alta fiabilidad los POIs de bajo y alto engagement. En cambio, la clase intermedia continúa siendo la más compleja, ya que agrupa casos con características menos definidas y más cercanas a los límites entre categorías (Tabla 2).

Table 2: Precisión, recobrado y F1 por clase en el conjunto de prueba

Clase	Precisión	Recobrado	F1	Soporte
Low (0)	1.00	0.92	0.96	75
Mid (1)	0.89	0.66	0.76	74
High (2)	0.73	0.97	0.83	75
Macro-avg	0.87	0.85	0.85	224

En términos de **pérdida (Loss)**, tanto el conjunto de entrenamiento como el de validación mostraron una **disminución progresiva y estable**, lo que indica que el modelo fue capaz de **aprender patrones relevantes** sin evidenciar señales claras de sobreajuste, manteniendo un aprendizaje controlado y consistente.

En cuanto a la **exactitud (Accuracy)**, la curva de validación se mantuvo **alineada con la de entrenamiento** durante todo el proceso, alcanzando valores cercanos al **85 %** en el conjunto de prueba. La ausencia de separaciones marcadas entre ambas curvas sugiere un **buen equilibrio entre la capacidad de aprendizaje y la generalización** a datos no vistos.

Finalmente, en las últimas épocas se observaron **señales claras de convergencia**, con métricas que se estabilizan y sin fluctuaciones abruptas. Este

comportamiento indica que el proceso de entrenamiento fue **adecuado y suficiente** para abordar la complejidad del problema planteado.

5 Conclusión

El modelo **EngageNet**, basado en una **arquitectura multimodal** que combina información visual y metadatos estructurados, alcanzó una **exactitud global del 85 %** y un **Macro-F1 de 0.85**, lo que evidencia un rendimiento sólido y equilibrado en un escenario de clasificación multiclase.

Desde una visión general, el modelo muestra una **buena capacidad para diferenciar niveles de engagement**, aprovechando tanto señales visuales como información contextual de los puntos de interés (POIs). El valor obtenido de Macro-F1 indica que el rendimiento es consistente entre clases y que no depende únicamente de una categoría concreta.

Al analizar el desempeño por clase, se observan comportamientos diferenciados:

- La clase **Low (0)** presenta un rendimiento prácticamente óptimo, con una **precisión del 100 %** y un **F1-score de 0.96**, lo que demuestra que el modelo identifica de forma muy fiable los POIs con bajo engagement.
- La clase **High (2)** alcanza un **recall muy elevado (0.97)**, indicando que el modelo es especialmente eficaz detectando POIs con alto engagement. Esta estrategia prioriza no perder elementos de alto valor, aunque implique una ligera reducción en la precisión.
- La clase **Mid (1)** continúa siendo la más compleja, con un **recall de 0.66**. Este resultado es esperable, ya que agrupa casos intermedios con características menos definidas y mayor solapamiento con las clases extremas.

Estos resultados indican que **EngageNet funciona especialmente bien**

identificando los extremos de engagement (bajo y alto), mientras que la clasificación de casos intermedios resulta más difícil.

5.1 Pasos a seguir y posibles mejoras

Como líneas de trabajo futuras, se proponen las siguientes acciones:

- **Refinar la clase Mid**, explorando estrategias como reponderación de clases, focal loss o el enriquecimiento de los metadatos disponibles.
- **Análisis de errores**, revisando los ejemplos mal clasificados para identificar patrones comunes o posibles carencias de información.
- **Ajustes finos del modelo multimodal**, evaluando una mayor capacidad en la rama tabular o la incorporación de mecanismos de atención en la fase de fusión.
- **Validación externa**, aplicando EngageNet a datos no vistos procedentes de otros contextos o regiones para evaluar su robustez.

En conjunto, los resultados obtenidos confirman que el **enfoque multimodal es adecuado** para el problema planteado y que **EngageNet constituye una base sólida y funcional**, con un margen claro de mejora para escenarios más complejos y cercanos a un entorno real.